水印

textGrain 水印更难检测：求和检验还能最优吗？

论文精读 · Bhattacharyya & Bonnerjee (2026)

arXiv:2610.17655 [stat.ML] · University of Pennsylvania

统计学专业 · 课程汇报

一页读懂：三个问题，三个答案

Q1 熵校准让检测更难吗？

是

检测边界从 $2p+q=1$ 收缩到 $p+q=1/2$

Q2 报告里的求和检验最优吗？

看列数 m

m 固定：最优

m 增长：会漏检

Q3 第二类错误衰减得够快吗？

不够

固定编辑比例时，指数速率严格低于最优

新

作者的方案：加权多尺度二项扫描（Algorithm 1）

不需要知道 NTP P_t、熵预算 β、编辑比例 ε；有限样本 size 精确有保证；达到上面所有检测边界和最优指数

一

背景：水印是怎么打上去的

LLM 逐 token 抽样 · Red-Green · Gumbel-max · textGrain

一 为什么要给 LLM 生成的文本加水印

- 欧盟《AI 法案》Article 50 要求 AI 生成内容**可被识别**；2026 年 6 月发布 Code of Practice on Transparency of AI-Generated Content
- 水印 = 读者**无感知**，持有密钥（Key）的检测者可做**统计检验**
- 检测者只需要：文本 + Key ；不需要模型本身，也不需要各位置的 NTP

1 **无偏 unbiased**

带水印 token 的边际分布 = 原 NTP ，不损害质量

2 **多样 stochastic**

同一 prompt 不应总生成同一段话

3 **可检测 detectable**

被人改写、混写之后仍能检出



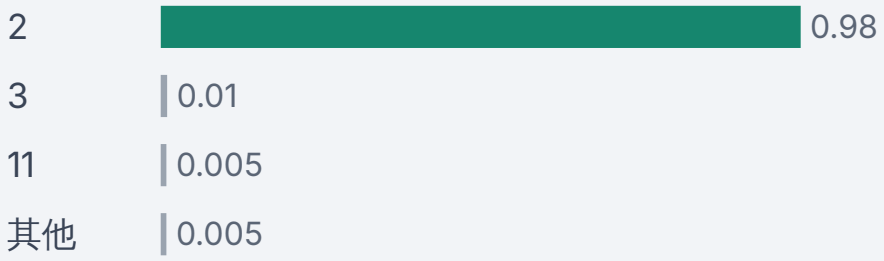
整篇论文的建模对象： Key 嵌入 → 编辑稀释 → 同一 Key 检验

一 生成 = 逐 token 抽样

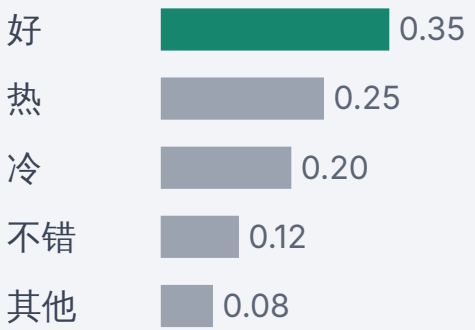
$$H(P) = -\sum_{w} P_w \log P_w, \qquad \Delta(P) = 1 - \max_{w} P_w$$

- Δ(P) 衡量模型有多“犹豫”：Δ 小 → **水印无处可藏**
- 有限词表下 H(P) 与 Δ·log(1/Δ) 同阶
- 伪随机：划分 g 、 Gumbel 表 Z 由 Hash(Key, 前文) 生成，检测者可复现；分析时视为独立随机变量
- Assumption 1 ： P_t 、 β_t 关于 F_{t-1} 可测； g_t 、 J_t 、 Z 每步独立抽取

示例 A ： 1 + 1 = ___ **Δ = 0.02**



示例 B ：今天天气很 ___ **Δ = 0.65**



示意数据

一 两条经典路线： Red-Green 与 Gumbel-max

Red-Green

Kirchenbauer et al. (2023)

- 按 Key 把词表分成绿表 / 红表（比例 γ）
- 生成时给绿色 token 的 logit 加 δ
- 检测：数绿色 token 个数 $|s|_G$，做单比例 z 检验

$$z = \frac{|s|_G - \gamma T}{\sqrt{T\gamma(1-\gamma)}}$$

优点：保留随机性，输出多样

缺点：有偏，扭曲了 NTP

Gumbel-max

Aaronson (2023)

- 每个 token 配一个由 Key 决定的 Gumbel 噪声 Z_w
- 取 $\log P_w + Z_w$ 最大者（Gumbel-max trick）

$$W = \arg\max_w \left\{\log P_w + Z_w\right\} \Rightarrow \mathbb{P}(W = w) = P_w$$

优点：无偏

缺点： Key 固定后完全确定，同一 prompt → 同一段话

textGrain （Li et al., 2026b）想两全： Red-Green 的随机性 + Gumbel-max 的无偏性；最接近的前作是 maximal coupling 去偏的 Red-Green （Xie et al., 2025）

一 textGrain 怎么生成一个 token

1 划分

g 把词表分成 B 个 block ，$P^{blk}_b = \Sigma_{g(w)=b} P_w$

2 密钥表

生成 B×m 的 Gumbel 表 Z_{bj} （标准化为 G_{bj} ）

3 熵约束 OT

解出耦合 $\pi_{P,\beta}$ ：行和 $= P^{blk}$ ，列和 $= 1/m$

4 抽样

J ~ Unif[m] ；按 m·π(b, J) 选 block ； block 内按 P 抽 token

抽到 J = 3

	j=1	j=2	j=3	j=4	行和
block 1	0.25	0.25	0.05	0.05	0.6
block 2	0	0	**0.20**	0.10	0.3
block 3	0	0	0	0.10	0.1

列和都是 1/4

- 格子里是耦合 π(b, j) ： Gumbel 值大的格子分到更多质量
- J = 3 时选 block 的概率 $= 4 \cdot \pi(\cdot, 3) = (0.2, \mathbf{0.8}, 0)$
- 选中 block 2 后，再按 P 在 block 2 内抽 token

一 数学定义：熵约束的最优传输

定义（1）

$$\pi_{P,\beta} \in \arg\max_{\pi} \sum_{b=1}^{B}\sum_{j=1}^{m} \pi(b,j)\, G_{bj}$$

$$\text{s. t.} \quad \pi \in \Pi(P^{\text{blk}}, m^{-1}\mathbf{1}), \quad D_{\text{KL}}(\pi \,\|\, P^{\text{blk}} \otimes m^{-1}\mathbf{1}) \le \beta H(P)$$

抽样

$$Q(w \mid J=j, g, G) = m\, \pi_{P,\beta}(g(w), j) \cdot \frac{P_w}{P^{\text{blk}}_{g(w)}}$$

无偏性

$$\mathbb{P}(W=w \mid g, G) = \sum_{j=1}^{m} \frac{1}{m} \cdot m\, \pi(g(w), j)\, \frac{P_w}{P^{\text{blk}}_{g(w)}} = P^{\text{blk}}_{g(w)} \cdot \frac{P_w}{P^{\text{blk}}_{g(w)}} = P_w$$

β 的作用

$$\beta = 0 \;\Rightarrow\; \pi_{P,0} = P^{\text{blk}} \otimes m^{-1}\mathbf{1}$$

- β = 0 ：π 与 Key 独立 → 生成的就是无水印文本（H_0）
- β 增大：Key 对 token 的影响增大；β = 1 时约束自动成立（KL = 互信息 ≤ $H(P^{blk}) \le H(P)$）

二

检测就是假设检验

枢轴量 · 稀疏混合 · minimax 检测边界

二 枢轴量与求和检验

检测者用 Key 复现 (g_t, Z_t, J_t)，计算枢轴量：

$$Y_t = F_G(Z_{t,\, g(W_t),\, J_t}), \qquad F_G(z) = e^{-e^{-z}}$$

$$H_0:\ Y_t \sim U(0,1) \ \Rightarrow\ -\log(1-Y_t) \sim \mathrm{Exp}(1)$$

求和检验（textGrain 报告的检测器，论文记作 $T_n^{\text{textGrain}}$）：

$$T_n = -\sum_{t=1}^{n} \log(1-Y_t) \ \sim\ \mathrm{Gamma}(n,1)$$

$$2T_n = -2\sum_{t=1}^{n} \log p_t \ \sim\ \chi^2_{2n}, \qquad p_t = 1 - Y_t$$

带水印：被选中的格子 Z 偏大 → Y 偏向 1 → p 值偏小 → T_n 偏大；拒绝域 T_n > Gamma(n,1) 的 1−α 分位数（精确 size）

和数理统计的连接

- 概率积分变换：X 连续 → F(X) ~ U(0,1)
- X ~ U(0,1) → −2 ln X ~ $\chi^2(2)$
- 独立 χ^2 可加 → $-2\Sigma \ln p_t \sim \chi^2(2n)$
- = Fisher 合并 p 值法
- Gamma(n,1) 精确分位数 → 精确 size α
- 依赖情形：$Y_t \mid F_{t-1} \sim U(0,1)$，鞅结构下同样成立

二 人类编辑 → 稀疏混合备择

$$H_0:\ Y_t \mid \mathcal{F}_{t-1} \ \sim\ U(0,1), \quad 1 \le t \le n$$

$$H_1:\ Y_t \mid \mathcal{F}_{t-1} \ \sim\ (1-\varepsilon_n) + \varepsilon_n\, f_{1,t}$$

人类改写 / 混写：每个位置以概率 ε_n 保留水印，否则 pivot 就是均匀的；$\varepsilon_n \to 0$ 即重度编辑

$$\varepsilon_n \asymp n^{-p}, \qquad \Delta_n \asymp n^{-q}, \qquad \beta_n \asymp n^{-r}$$

p 编辑强度

$\varepsilon_n \approx n^{-p}$ ： p 越大，保留下来的水印越少

q 模型确定性

$\Delta_n \approx n^{-q}$ ： q 越大，模型越笃定，水印越难藏

r 熵预算

$\beta_n \approx n^{-r}$ ： r 越大， Key 对 token 的影响越弱

背景：稀疏异质混合检测（Donoho & Jin, 2004, 2015）；稀疏水印 regime （Li et al., 2025b, 2026a ； Xie et al., 2025）

二 什么叫“能检测”： minimax 检测边界

$$R_n = \inf_{\phi_n} \left\{ \mathbb{E}_0 \phi_n + \sup_{P_1 \in \mathcal{H}_{1,n}} \mathbb{E}_1 (1 - \phi_n) \right\}$$

$R_n \to 0$ ：存在一致检验

$R_n \to 1$ ：任何检验都等于瞎猜

启发：混合密度的 χ^2 散度

$$\chi^2(1 - \varepsilon + \varepsilon f \,\|\, U) = \varepsilon^2 \chi^2(f \,\|\, U)$$

每个位置贡献 $\varepsilon^2\chi^2(f_1\|U)$ ，n 个位置累加 → 信息量

$$I_n = n \varepsilon_n^2 \Delta_n \min \left\{ \Delta_n,\ \beta_n H(\Delta_n) \right\}$$

Theorem 2.4 （m 固定， Assumption 1–2 ）

$$R_n \to 0 \ \Leftrightarrow\ I_n \to \infty, \qquad I_n \to 0 \ \Rightarrow\ R_n \to 1$$

怎么读 I_n

- n ：打分的 token 数
- ε_n^2 ：残留水印的平方，稀疏性的惩罚很重
- $\Delta_n \cdot \min\{\Delta_n, \beta_n H\}$ ：单个 token 的 χ^2 信号（ Theorem 2.2 ）

信息量 I_n 增大 →

$I_n \to 0$
不可检测（ $R_n \to 1$ ）

$I_n \approx 1$
边界上（ $\liminf R_n > 0$ ）

$I_n \to \infty$
可检测（ $R_n \to 0$ ）

三

发现①： textGrain 更难检测

Theorem 2.2 · Corollary 2.5 · Example 1

三 单个 token 的信号有多强（Theorem 2.2）

Theorem 2.2 （m ≥ 2 固定， Assumption 1–2 ）

$$\chi^2(f_{1,P,\beta} \,\|\, U) \asymp \Delta(P) \cdot \min\left\{\Delta(P),\ \beta H(P)\right\}$$

对任意固定的非降 h ∈ L² （含报告用的 h(y) = −log(1−y) ）：

$$\mathbb{E}_1 h(Y) - \mathbb{E}_0 h(Y) \asymp \sqrt{\Delta(P) \cdot \min\left\{\Delta(P),\ \beta H(P)\right\}}$$

β ≈ 1 时熵约束不起作用：

$$H(P) \geq \Delta\log(1/\Delta) \gg \Delta \ \Rightarrow\ \min\left\{\Delta, \beta H\right\} = \Delta \quad (\beta \asymp 1)$$

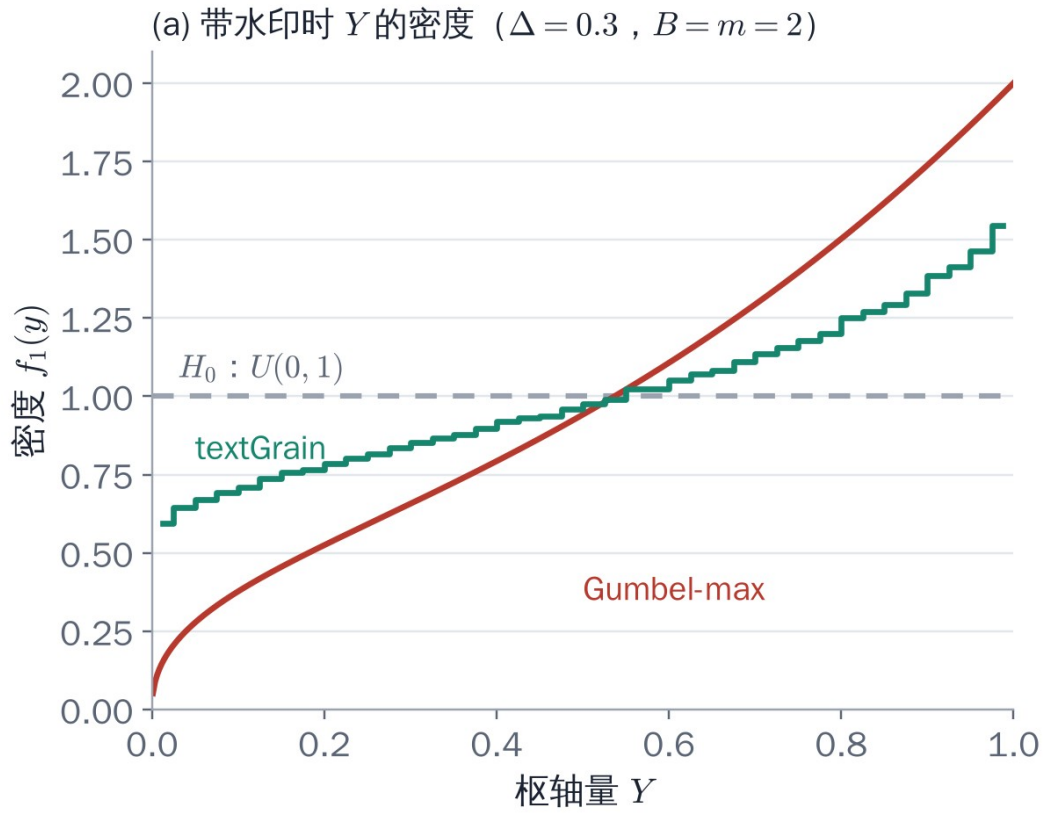
对比 Gumbel-max （Li et al., 2026a ： shift 与 H(P) 同阶）：

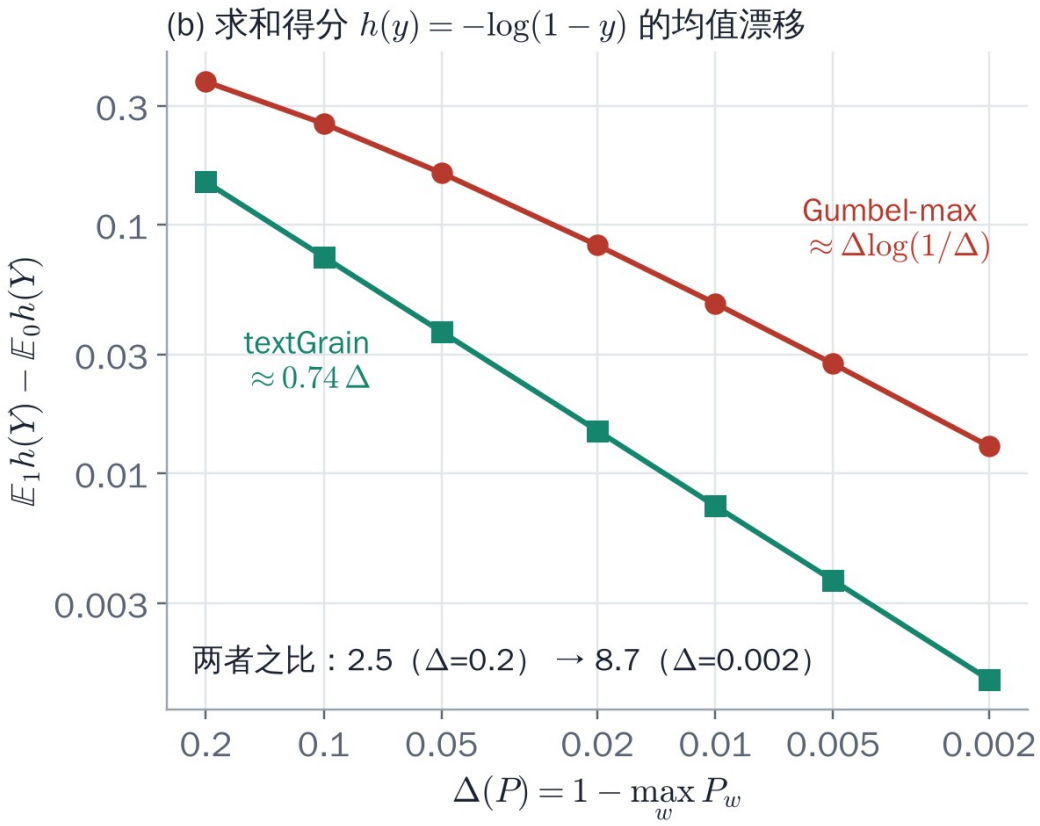
$$\frac{\mathrm{shift}_{\mathrm{tG}}}{\mathrm{shift}_{\mathrm{GM}}} \asymp \frac{\Delta(P)}{H(P)} \asymp \frac{1}{\log(1/\Delta)} \to 0$$

每个 token 的证据少了一个 log(1/Δ) 因子

- Δ = 0.01 时 log(1/Δ) ≈ 4.6
- 直觉： Gumbel-max 让 Key 完全决定 token ； textGrain 只在有限的 B×m 个格子上做耦合， Key 的影响被“摊薄”
- 下一页：用模拟验证这个结论

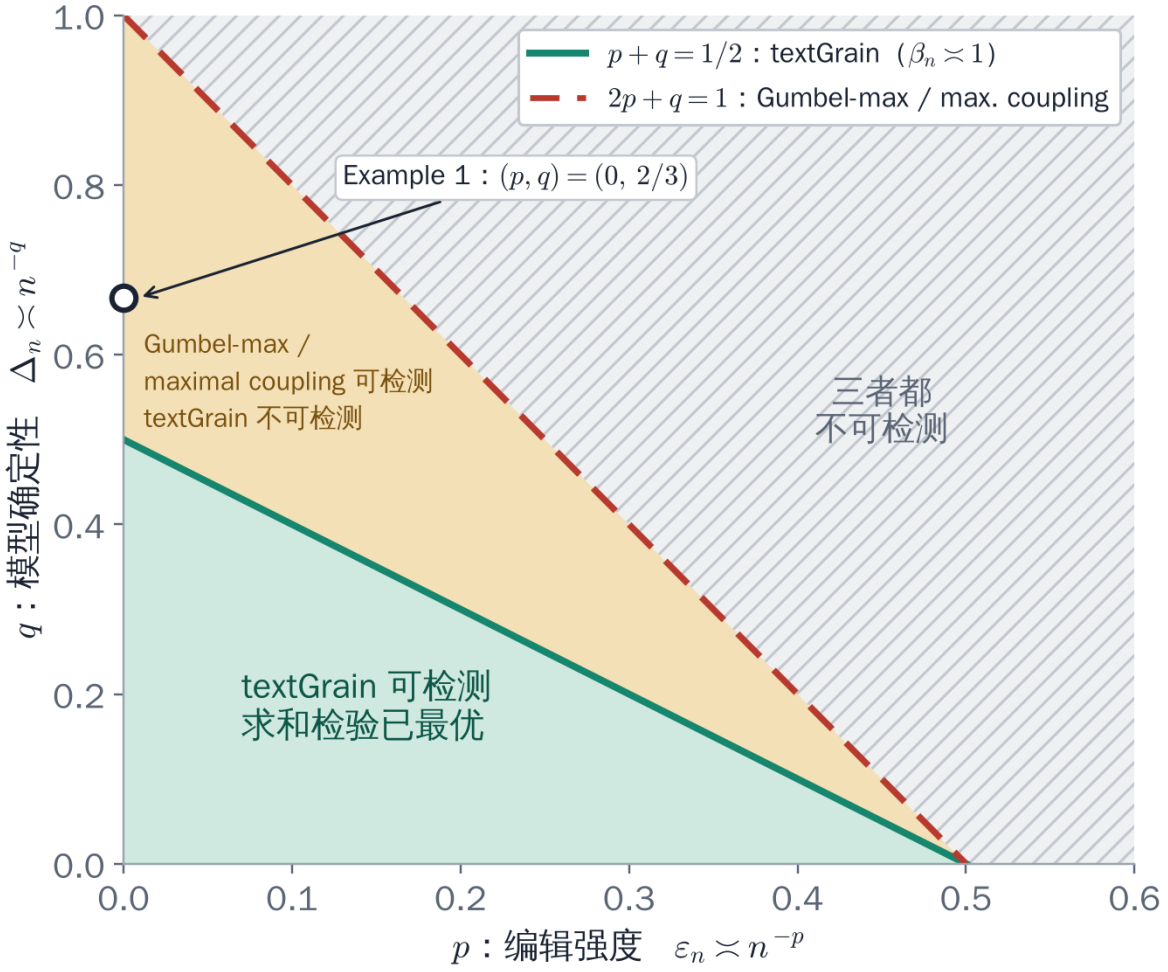
三 补充模拟：验证 Remark 2.3





设定： B = m = 2 ，固定划分， β = 1 ， P = (1−Δ, Δ) 。 textGrain 用条件期望 + 控制变量 Monte Carlo （每点 4×10^5 次）； Gumbel-max 用闭式 $\Sigma_w P_w[\psi(1+1/P_w)+\gamma] - 1$

三 相图：可检测区域缩小了（Corollary 2.5）



Corollary 2.5 （m 固定）

$$\beta_n \asymp 1: \quad I_n \asymp n^{1-2p-2q}$$

- 边界 2p + 2q + r = 1 ； $\beta_n \approx 1$ 时即 **p + q = 1/2**
- Gumbel-max 与 maximal coupling ： 2p + q = 1
- q > 0 时 textGrain 的可检测区域严格更小
- 边界面上： q 、 r 都大于 0 时仍可检测（I_n 对数发散），否则不可

黄色区域 = 为“自然、多样”付出的代价

Gumbel-max 能检出、 textGrain 检不出的文本

三 代价从哪里来？ Example 1

- 设定： B = m = 2 ， P_δ = (1−δ, δ 均分给其余 token) ，固定划分
- 熵预算 $\beta_\delta = c\delta / H(P_\delta)$ ：两种方案损失**同样多的熵 cδ**
- RG （ Randomized Gumbel-max ）：以概率 $1-a_\delta$ 按原分布抽样，以概率 a_δ 用 Gumbel-max 选 block ；同样无偏

结论

检测变难不是“保留熵”的必然代价，而是 textGrain 用有限列 OT 的构造带来的

同一设定： $\Delta_n = n^{-2/3}, \quad \varepsilon_n = 1$

textGrain

$$I_n^{\mathrm{tG}} \asymp n\Delta_n^2 = n^{-1/3} \to 0 \quad \Rightarrow \quad R_n \to 1$$

两个假设渐近不可区分

RG （同样的熵损失）

$$\inf_\phi \left\{ \mathbb{E}_0\phi + \mathbb{E}_{\mathrm{RG}}(1-\phi) \right\} \to 0$$

存在一致检验（ Proposition B.1 ）

四

发现②：求和检验什么时候最优

Theorem 3.1 · Proposition 3.4 · Theorem 2.8

四 固定列数：求和检验已经最优（Theorem 3.1）

(a) 任意固定的非降得分 h ，Chebyshev 型阈值：

$$\phi_{n,h} = \mathbf{1}\left\{\sum_{t=1}^{n} h(Y_t) > n\int_0^1 h + \sigma_h\sqrt{n}\, a_n\right\}, \quad a_n \to \infty,\ a_n = o(\sqrt{I_n})$$

(b) 报告的 T_n，用 Gamma(n,1) 精确分位数校准：

$$\mathbf{1}\{T_n > c_{n,\alpha_n}\}, \quad \alpha_n = \frac{\alpha_0}{\log(n+e)}: \quad \frac{I_n}{\log\log n} \to \infty \ \Rightarrow\ \text{error} \to 0$$

水印方案	最优检测边界	求和检验的边界	求和检验最优？
Gumbel-max	2p + q = 1	p + q = 1/2	否（Li et al., 2026a, Thm 4）
Maximal coupling	2p + q = 1	p + q = 1/2	否（Xie et al., 2025）
textGrain （m 固定，β ≈ 1）	**p + q = 1/2**	**p + q = 1/2**	是（Theorem 3.1）

反转：最优边界缩到了求和检验的边界 → 复杂检测器没有提升空间（与 Gumbel-max 的结论正好相反）

四 Fisher 法为什么在这里没有失败？

稀疏高斯混合 Donoho & Jin (2004)

- 信号集中在**极端尾部**
- 求和把少数极端值稀释掉
- → Fisher 失效，需要 Higher Criticism 等尾部敏感的统计量

vs

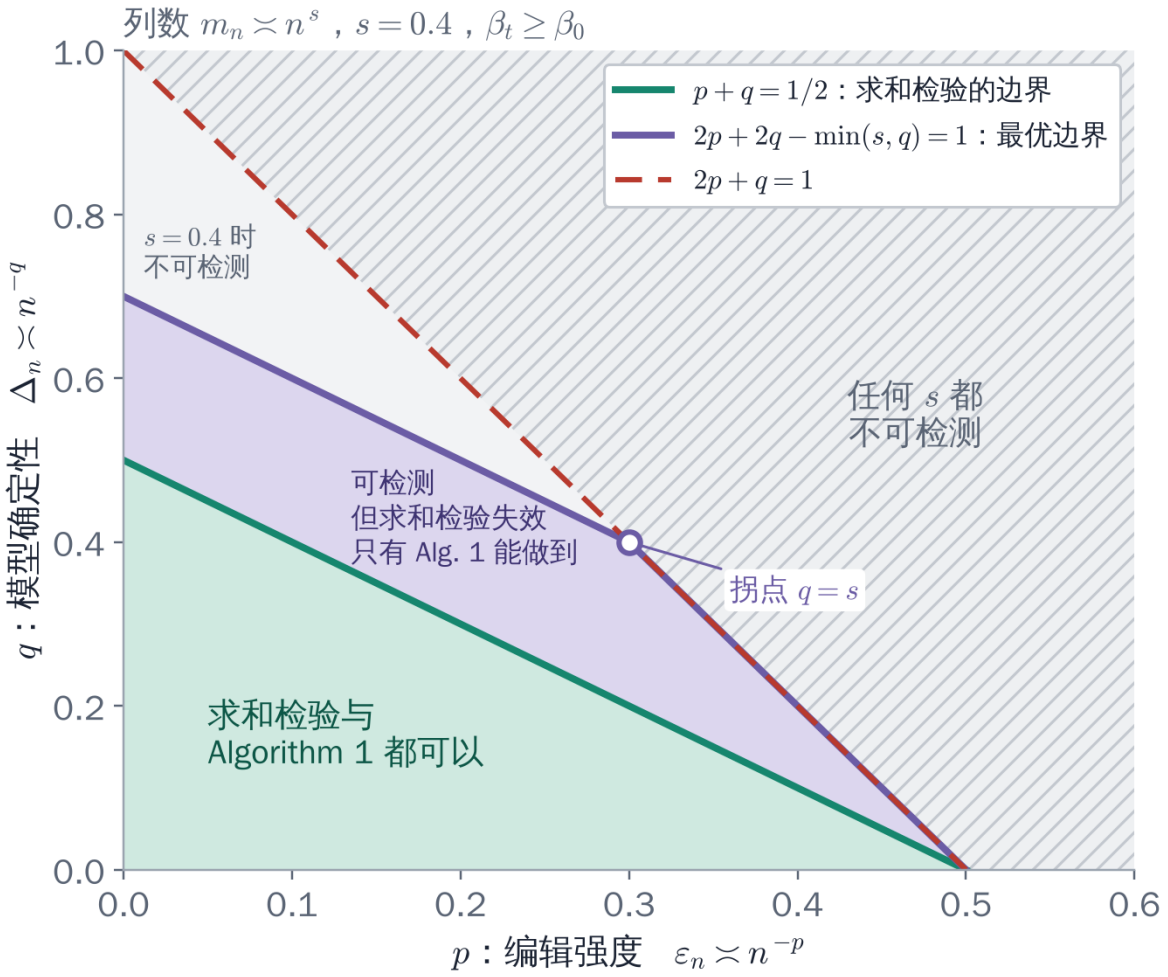
textGrain ， m 固定

- Theorem 2.2 ：**任何**单调得分的均值漂移都与 √（信息量）同阶
- 信号“摊开”在整个分布上
- → 求和不吃亏， Fisher 法已最优

Remark 3.2 ： $2T_n = -2\Sigma \log p_t$ 正是 Fisher 合并统计量

列数增长时，信号可以集中到很小的上尾 → 求和检验开始漏检（下一页）

四 列数增长：求和检验会漏检



每个位置的信息（强熵预算）

$$\chi^2 \asymp \Delta \cdot \min\{m\Delta,\ 1\}$$

列数有用，但 m ≈ 1/Δ 后饱和；生成成本 O(Bm) → 计算—精度权衡

Theorem 2.8 （ $m_n \approx n^s$ ， $\beta_t \geq \beta_0$ ）：最优边界

$$2p + 2q - \min(s, q) = 1$$

Proposition 3.4 ： T_n 的灵敏度与 m 无关

$$\sqrt{n}\,\varepsilon_n \Delta_n \log(e/\Delta_n) \to 0 \ \Rightarrow\ T_n \text{ powerless}$$

- 紫色区域：可检测，但 T_n 任何阈值都无效
- 弱熵预算（ Thm 2.10 、 3.3 ）：信号不集中， T_n 仍最优

五

发现③：效率与自适应检验

Theorem 4.2 · Proposition 4.4 · Algorithm 1

五 固定 ε：第二类错误能衰减多快

Theorem 4.2 （最优指数 = Chernoff–Stein ）

$$\limsup_{n} \; -\tfrac{1}{n}\log \sup_{P_1} \mathbb{E}_1(1-\psi_n) \;\le\; \inf_{q\in\mathcal{Q}_\Theta}\left\{-\int_0^1 \log q(y)\,dy\right\} \qquad -\int_0^1 \log q(y)\,dy = D_{\mathrm{KL}}(U\,\|\,q)$$

Proposition 4.4 （求和检验的指数 = Cramér 大偏差速率）

$$\lim_{n} \; -\tfrac{1}{n}\log P_q(T_n \le c_{n,\alpha}) = \sup_{\lambda\ge 0}\left\{-\lambda - \log\int_0^1 (1-y)^{\lambda} q(y)\,dy\right\}$$

$$0 \;<\; \sup_{\lambda\ge 0}\{\cdots\} \;<\; -\int_0^1 \log q(y)\,dy$$

只要 q ≠ 1 ，就严格小于最优

为什么？似然比检验用 Σ log q(Y$_t$) ；求和检验 = 似然比检验 ⇔ q(y) ∝ (1−y)$^{-\theta}$ ，在 y → 1 处无界

而 textGrain 的 f$_1$ 有界（≤ min(B, m) ）→ 求和检验在**每个**固定备择下都严格更慢

五 Algorithm 1 ：加权多尺度二项扫描

门槛网格：二进位 + 越来越密的均匀网格（$L_n = \max\{2, \lceil \log(n+1) \rceil\}$）

$$\mathcal{U}_n = \{2^{-j} : 1 \le j \le \lceil \log_2 n \rceil\} \cup \{k/L_n : 1 \le k < L_n\}$$

权重：一半留给中位数

$$w_n(u) = \frac{1}{2|\mathcal{U}_n|} + \frac{1}{2}\mathbf{1}\{u = 1/2\}$$

二项 KL 散度

$$\mathrm{kl}(a, u) = a \log \frac{a}{u} + (1-a) \log \frac{1-a}{1-u}$$

扫描统计量与拒绝域（$p_t = 1 - Y_t$）

$$T_n^{\mathrm{scan}} = \max_{u \in \mathcal{U}_n,\ \hat{F}_n(u) > u} \{ n\, \mathrm{kl}(\hat{F}_n(u), u) + \log w_n(u) \}$$

$$\phi_{n,\alpha} = \mathbf{1}\{T_n^{\mathrm{scan}} > \log(1/\alpha)\}, \qquad \hat{F}_n(u) = \frac{1}{n} \sum_t \mathbf{1}\{p_t \le u\}$$

直觉

- 每个 u ： p 值落在 [0, u] 的比例是否偏多？→ 二项似然比 n·kl
- 小的二进位 $u = 2^{-j}$ ：抓集中在**极端尾部**的信号
- u = 1/2 占一半权重：抓“摊开”的信号
- 网格逐渐加密：逼近最优指数
- 只用 p_t ，不需 P_t 、 β_t 、 ε_n ； O(n log n)
- = 单侧加权 Berk–Jones 统计量，思想同 Higher Criticism

五 size 为什么有保证：一行证明（Theorem 4.5）

Step 1 ：单个 u 的二项 Chernoff 界（H_0 下 $n\hat{F}_n(u) \sim \mathrm{Bin}(n, u)$ ；鞅情形逐步条件化同样成立）

$$P_0\big(\hat{F}_n(u) \geq a\big) \leq e^{-n\,\mathrm{kl}(a,\,u)}, \qquad a > u$$

Step 2 ：加权 Bonferroni （union bound ）

$$P_0\big(T_n^{\mathrm{scan}} > \log\tfrac{1}{\alpha}\big) \leq \sum_{u \in \mathcal{U}_n} P_0\Big(n\,\mathrm{kl} > \log\tfrac{1}{\alpha\, w_n(u)}\Big) \leq \sum_u \alpha\, w_n(u) = \alpha$$

功效：只要某个 u 处信号有超额尾部质量 d （$f_{1,t} \leq M$）

$$\int_{1-u}^{1} f_{1,\,t}(y)\,dy \geq u + d \quad \text{and} \quad \tfrac{n\varepsilon_n^2 d^2}{8Mu} > \log\tfrac{1}{\alpha\, w_n(u)} \quad \Rightarrow \quad P_1(\phi_{n,\,\alpha} = 0) \leq \tfrac{4Mu}{n\varepsilon_n^2 d^2}$$

代价： $\log(1/w_n(u)) = O(\log\log n)$

Thm 4.6

m 固定：达到 Thm 2.4 的边界，和 T_n 一样好

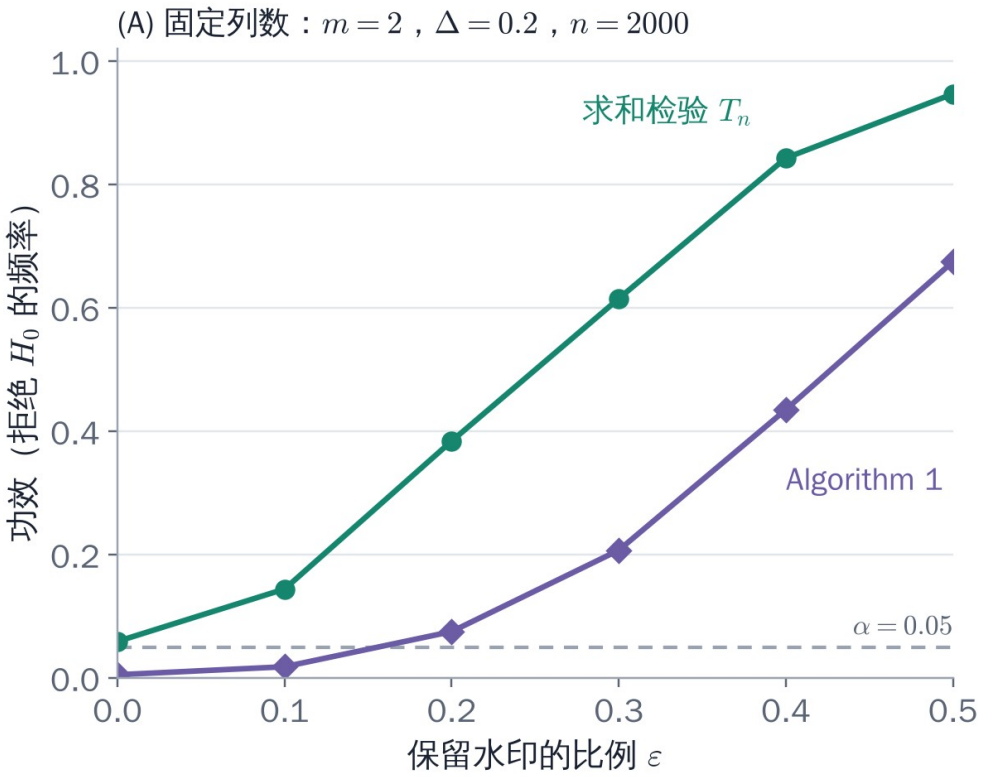
Thm 4.8

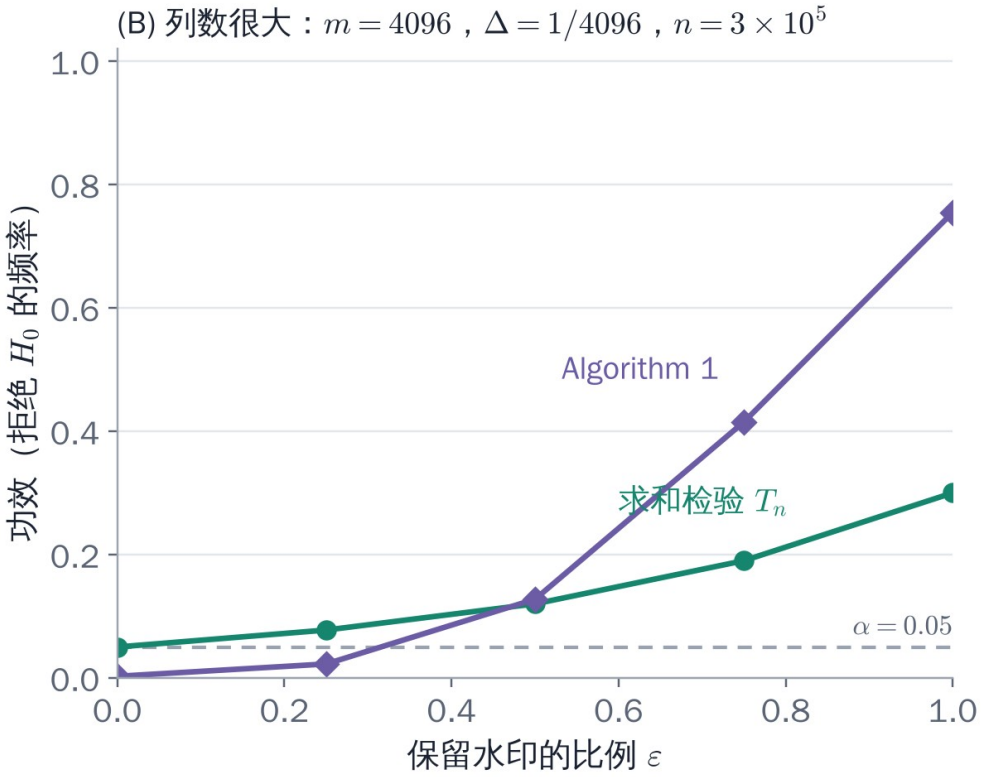
列数增长：达到 T_n 达不到的紫色区域

Thm 4.9

固定 ε ：达到最优指数 inf KL(U‖q)

五 补充模拟：理论最优 ≠ 有限样本最优





(A) m 固定： T_n 更强； Algorithm 1 付出常数代价， size 很保守（实测 ≈ 0.5% ，名义 5% ）

(B) 信号藏在极小尾部： Algorithm 1 胜出（ ε = 1 时功效 0.76 vs 0.30 ），对应 Proposition 3.4

结论总表

情形	最优检测边界 / 指数	报告的求和检验 T_n	Algorithm 1
m 固定， $\beta_n \approx n^{(-r)}$	$2p + 2q + r = 1$	达到（Thm 3.1）	达到（Thm 4.6 、 Cor 4.7）
$m_n \approx n^s$ ，强熵预算	$2p + 2q - \min(s, q) = 1$	只到 $p + q = 1/2$ （Prop 3.4）	达到（Thm 4.8a）
m_n 增长，弱熵预算	$n\varepsilon^2\Delta\kappa \to \infty$	达到（Thm 3.3）	达到（Thm 4.8b）
ε 固定：指数效率	$\inf KL(U\|q)$	严格更慢（Prop 4.4）	达到（Thm 4.9）

对比： Gumbel-max / maximal coupling 的边界都是 $2p + q = 1$ ，其上的求和检验只到 $p + q = 1/2$

κ_n ：熵预算 $\beta_t H(P_t)$ 的量级（Theorem 2.10）

评价、局限与讨论

我的评价

- 框架完整：边界 + 求和检验 + 效率 + 自适应检验
- 反直觉的结论：更难检测 → 简单方法反而最优
- Example 1 把“保留熵”与“构造方式”的代价分开

局限

- 预印本（2026-10-13），详细证明尚未公开
- 假设每个位置用新鲜密钥；官方实现只给上下文窗口的首次出现打分，重复上下文仍是 open problem
- 渐近结论：有限样本下常数很重要（见补充模拟）

讨论

1. 第一类错误 = 冤枉人类作者。α 应该设多大？
2. 质量（无偏、多样） vs 可检测性：β 该由谁来决定？
3. 本文的 AI usage statement 声明用了 ChatGPT 与 Claude 打磨定理表述。AI 辅助写作该如何披露？

参考文献

Bhattacharyya, S. & Bonnerjee, S. (2026). textGrain watermarking is harder to detect: can sum-tests still do it optimally? arXiv:2610.17655.

Li, X., Wen, G., Chen, X., Long, Q., et al. & Su, W. (2026b). textGrain: Entropy-calibrated watermarking for language model text. Technical report.

Li, X., Ruan, F., Wang, H., Long, Q. & Su, W. J. (2026a). Robust detection of watermarks for large language models under human edits. JRSS-B, 88(2), 491–515.

Li, X., Ruan, F., Wang, H., Long, Q. & Su, W. J. (2025a). A statistical framework of watermarks for large language models: Pivot, detection efficiency and optimal rules. Annals of Statistics, 53(1).

Xie, Y., Li, X., Mallick, T., Su, W. & Zhang, R. (2025). Debiasing watermarks for large language models via maximal coupling. JASA, 120(551), 1424–1436.

Kirchenbauer, J., Geiping, J., Wen, Y., Katz, J., Miers, I. & Goldstein, T. (2023). A watermark for large language models. ICML.

Aaronson, S. (2023). Watermarking of large language models. Talk at the Simons Institute.

Donoho, D. & Jin, J. (2004). Higher criticism for detecting sparse heterogeneous mixtures. Annals of Statistics, 32(3), 962–994.

Jager, L. & Wellner, J. A. (2007). Goodness-of-fit tests via phi-divergences. Annals of Statistics, 35(5), 2018–2053.

谢谢！欢迎提问

1

熵校准有代价

textGrain 的边界 p + q = 1/2 严格小于 Gumbel-max 的 2p + q = 1

2

代价带来反转

m 固定时，最朴素的求和检验已经最优

3

但不是全部

列数增长或看指数效率时，需要 Algorithm 1 这样的自适应扫描

论文： arXiv:2610.17655 · 补充模拟的设定见第 15 、 26 页备注